

Catalogue de Projets MLOps

Classification supervisée avec datasets Kaggle

Formation Machine Learning & MLOps

Contexte général

Ce document présente un ensemble de projets pédagogiques destinés aux apprenants en **Machine Learning et MLOps**. Chaque projet repose sur un jeu de données réel disponible sur la plateforme **Kaggle** et vise à mettre en pratique :

- L’analyse exploratoire des données (EDA)
- La modélisation supervisée
- Les bonnes pratiques de structuration de projet
- Le versionnement du code avec GitHub

Contraintes techniques

- Langage : **Python**
- Plateforme de versionnement : **GitHub**
- Source des données : **Kaggle**
- Travail individuel ou en binôme

1 Projet 1 – Détection de fraude bancaire

Description

Les transactions frauduleuses représentent un enjeu majeur pour les institutions financières. L’objectif est de concevoir un modèle capable d’identifier automatiquement les transactions suspectes.

Dataset

- **Credit Card Fraud Detection**
- Lien : <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>

Richesse pour l'EDA

- Fort déséquilibre des classes
- Variables issues de PCA
- Analyse temporelle
- Détection d'anomalies

Travail attendu

- Analyse exploratoire complète
- Gestion du déséquilibre des classes
- Comparaison de plusieurs modèles
- Analyse des faux négatifs

2 Projet 2 – Prédiction du churn client

Description

La perte de clients (churn) est un problème critique dans les télécommunications. Le projet vise à prédire quels clients sont susceptibles de quitter l'opérateur.

Dataset

- **Telco Customer Churn**
- Lien : <https://www.kaggle.com/datasets/blastchar/telco-customer-churn>

Richesse pour l'EDA

- Variables numériques et catégorielles
- Analyse comportementale
- Étude des contrats et paiements

Travail attendu

- Feature engineering
- Encodage catégoriel
- Modèles interprétables

3 Projet 3 – Détection de défauts industriels

Description

Dans un contexte industriel, détecter les produits défectueux en amont permet de réduire les coûts de production et d'améliorer la qualité.

Dataset

- **Bosch Production Line Performance**
- Lien : <https://www.kaggle.com/c/bosch-production-line-performance>

Richesse pour l'EDA

- Plus de 900 variables
- Données bruitées et manquantes
- Problématique de haute dimension

Travail attendu

- Sélection de variables
- Modèles robustes
- Analyse des performances

4 Projet 4 – Diagnostic médical assisté

Description

L'objectif est d'aider au diagnostic médical à partir de données cliniques tout en tenant compte des enjeux d'interprétabilité.

Datasets

- Heart Disease : <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

Richesse pour l'EDA

- Analyse démographique
- Corrélations cliniques
- Étude des faux négatifs

5 Projet 5 – Détection de fake news

Description

La propagation de fausses informations est un enjeu sociétal majeur. Ce projet vise à classifier automatiquement des articles de presse.

Dataset

- **Fake News Detection**
- Lien : <https://www.kaggle.com/datasets/clmentbisailon/fake-and-real-news-dataset>

Richesse pour l'EDA

- Analyse lexicale
- Longueur des textes
- Distribution des classes

6 Projet 6 – Scoring de risque de crédit

Description

Les banques évaluent le risque de défaut avant d'accorder un crédit. L'objectif est de prédire la probabilité de non-remboursement.

Dataset

- **Home Credit Default Risk**
- Lien : <https://www.kaggle.com/c/home-credit-default-risk>

Richesse pour l'EDA

- Variables socio-économiques
- Valeurs manquantes complexes
- Analyse des biais

Structure GitHub attendue

```
project-mlops/  
  data/  
  notebooks/
```

```
src/  
requirements.txt  
README.md  
.gitignore
```